Autores:
Lucia Fuentes González
César Sánchez Parra
Adrián Quindimil Rengel

Problema de negocio

Introducción

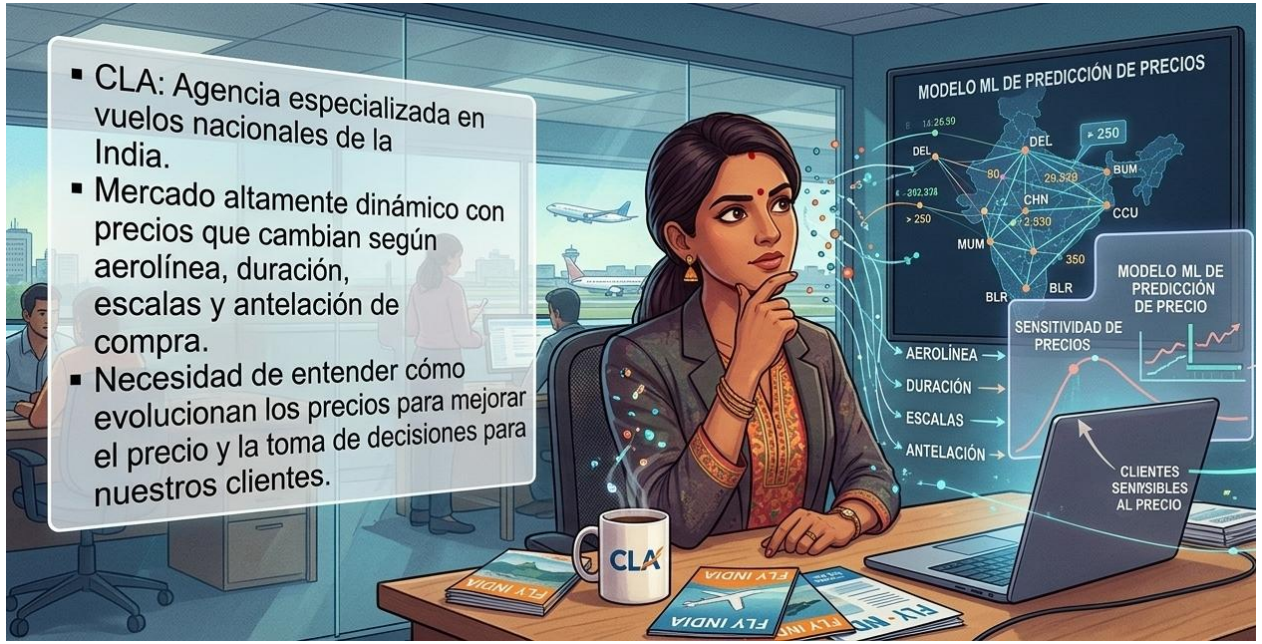

Datos disponibles

- **Fuente:** *Web scraping* realizado el 10/02
- **Horizonte:** Del 11/02 al 31/03
- **Enfoque:** Tendencias de precio inmediatas (sin estacionalidad anual)

Limpieza y transformación de datos (ETL)

Transformer	Variable inicial	Función	Variable final
1 **DurationTransformer**	"time_taken"	convertir duración	“duration(h)”
2 **TimeCategoryTransformer**	"dep_time“/ "arr_time"	Categorizar horas	"dep_time_cat" "arr_time_cat"
3 **StopCleaner**	"stop"	Extraer nº escalas	"stop_num"
4 **DaysLeftTransformer**	"date"	Calcular días restantes	"days_left"
5 **ColumnDropper**	“cols_to_drop”	Eliminar columnas irrelevantes	n.a.
6 **PriceToFloat**	"price"	convertir price a float	"price"
7 **AirlineGrouper**	"airline"	Agrupar las aerolíneas	"airline"
8 **DropDuplicates**	n.a.	Eliminar los duplicados	n.a.

*n.a. = no aplica

Análisis del target (“price”)

Distribución de precios significativamente diferente…

… decidimos desarrollar 2 modelos en lugar de 1

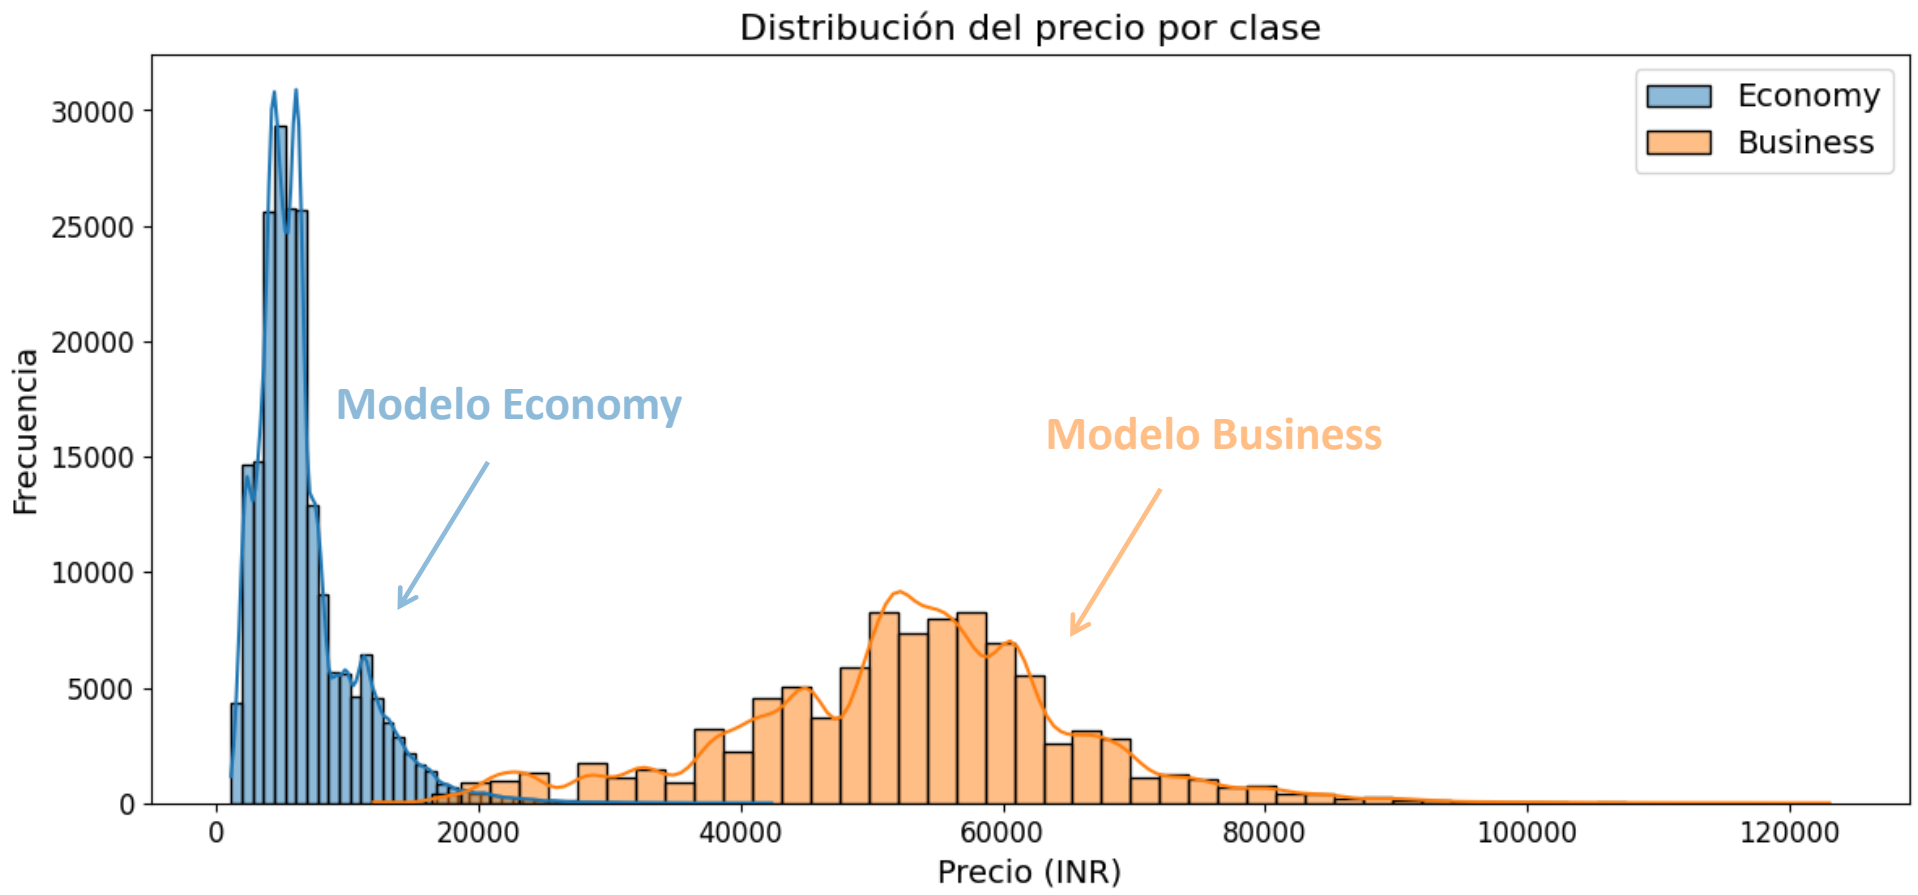

Selección de *features* (dataset economy)

- **Test estadístico ANOVA**
  (relación target-categóricas)

Variable	P-value (p < 0,05)	Selección (si/no)
“Airline”	0	Si
“From”	0	Si
“To”	2,03 e^{-241}	Si
“dep_time_cat”	4,61 e^{-289}	Si
“arr_time_cat”	0	Si

p-value < 0,05 y corr. > 0,2:

¡Nos quedamos con todas!

- **Matriz de correlación**
  (relación lineal variables numéricas)

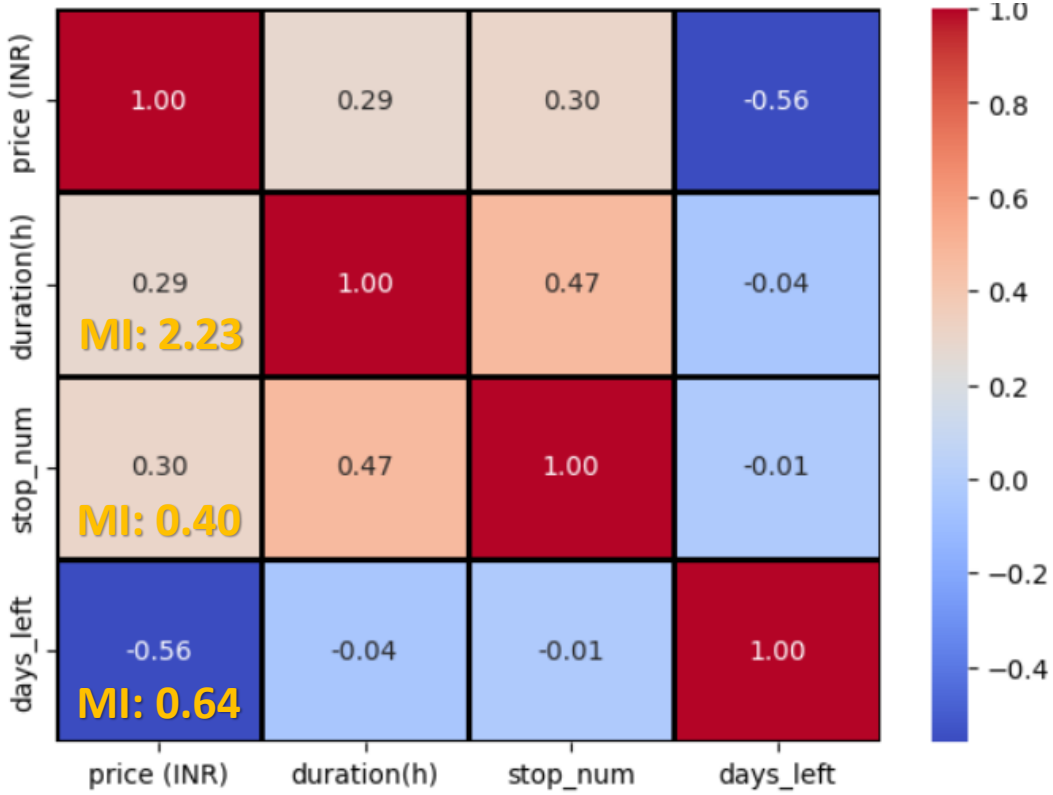

MI: Mutual Information

Selección de *features* (dataset business)

- **Test estadístico ANOVA**
  (relación target-categóricas)

Variable	P-value (p < 0,05)	Selección (si/no)
“Airline”	0	Si
“From”	0	Si
“To”	0	Si
“dep_time_cat”	1,65 e^{-60}	Si
“arr_time_cat”	0	Si

p-value < 0,05 y corr. > 0,2:

¡Nos quedamos con todas!

- **Matriz de correlación**
  (relación lineal variables numéricas)

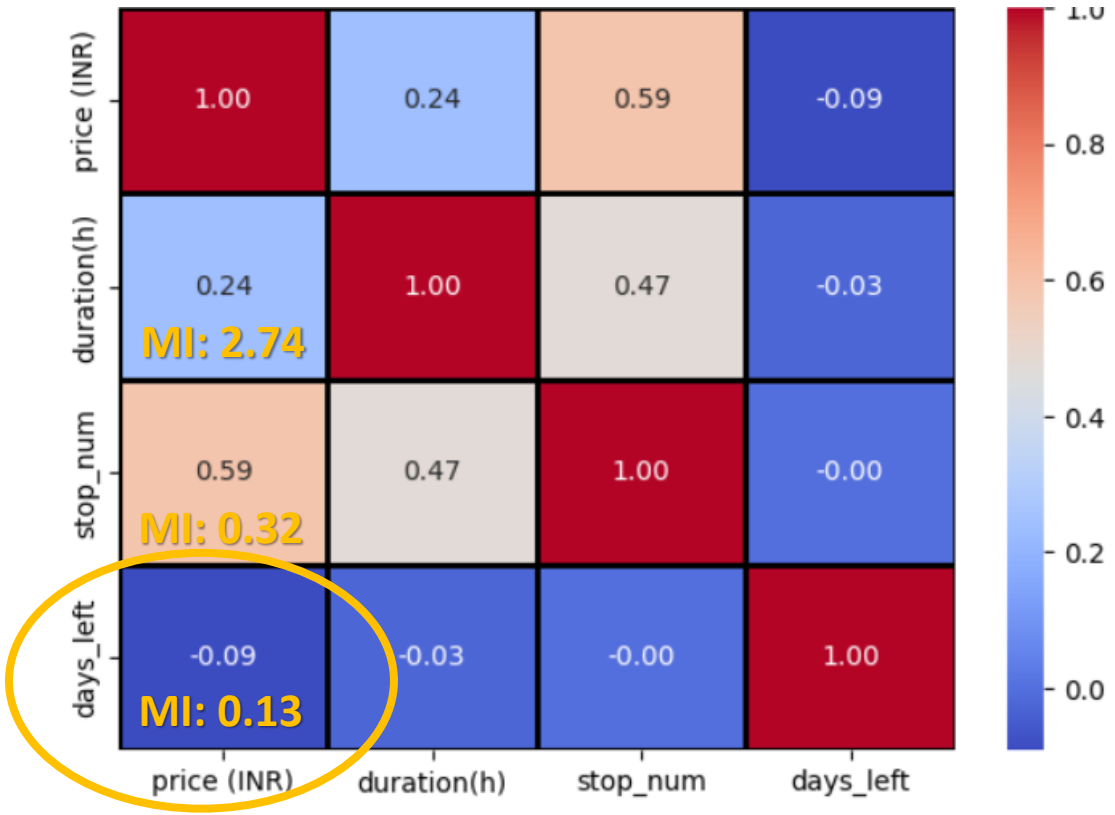

MI: Mutual Information

Tratamiento de *features*

Variables categóricas:

- Codificamos a través de OneHotEncoder.

```
preprocessor_trees = ColumnTransformer([
    ("procesar_cat_OH", OneHotEncoder(handle_unknown = "ignore"), features_cat_reg)
], remainder = "passthrough")
```

Variables numéricas:

- No las vamos a tratar --> modelos basados en árboles

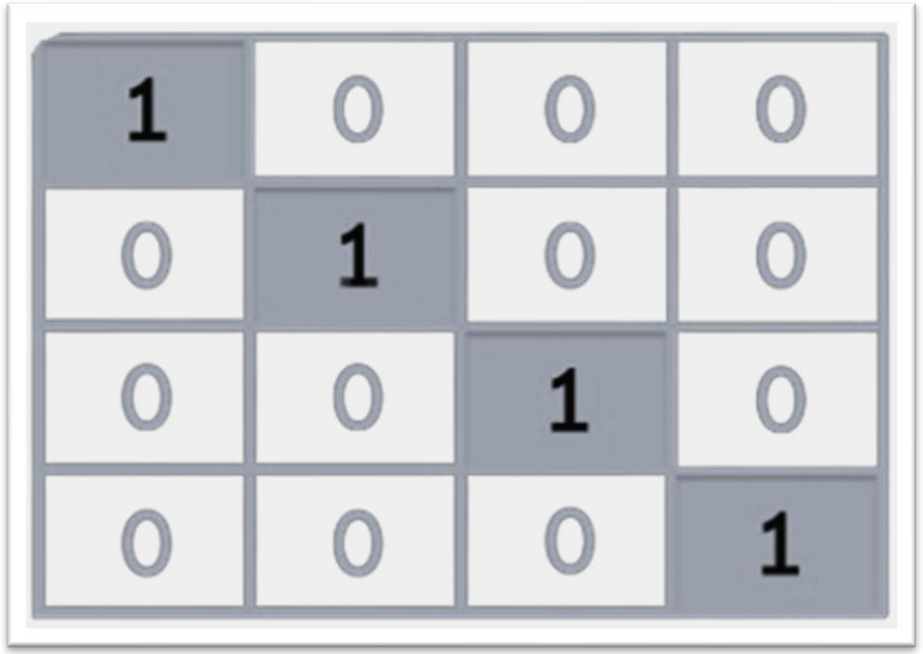

Elección de modelos: discriminación por *cross validation*

FLIGHT INTELLIGENCE
TRAVEL AGENCY INDIA

M1: RandomForestRegressor (Baseline)

RMSE	MAE	R2
Dataset Economy		
2240	1465	0.64
Dataset Business		
8811	6473	0.54

M2: XGBRegressor

RMSE	MAE	R2
Dataset Economy		
1771	**1104**	**0.78**
Dataset Business		
5536	**3826**	**0.81**

M3: LGBMRegressor

RMSE	MAE	R2
Dataset Economy		
1907	1218	0.74
Dataset Business		
6715	4842	0.73

¡Escogemos el modelo XG-Boost!

Optimización con Optuna (dataset economy)

- Optimización bayesiana hiperparámetros:
  - "n_estimators": 741
  - "max_depth": 8
  - "learning_rate": 0,089
  - "subsample": 0,908
  - "colsample_bytree": 0,902

RMSE = **1329 INR** (~13€)

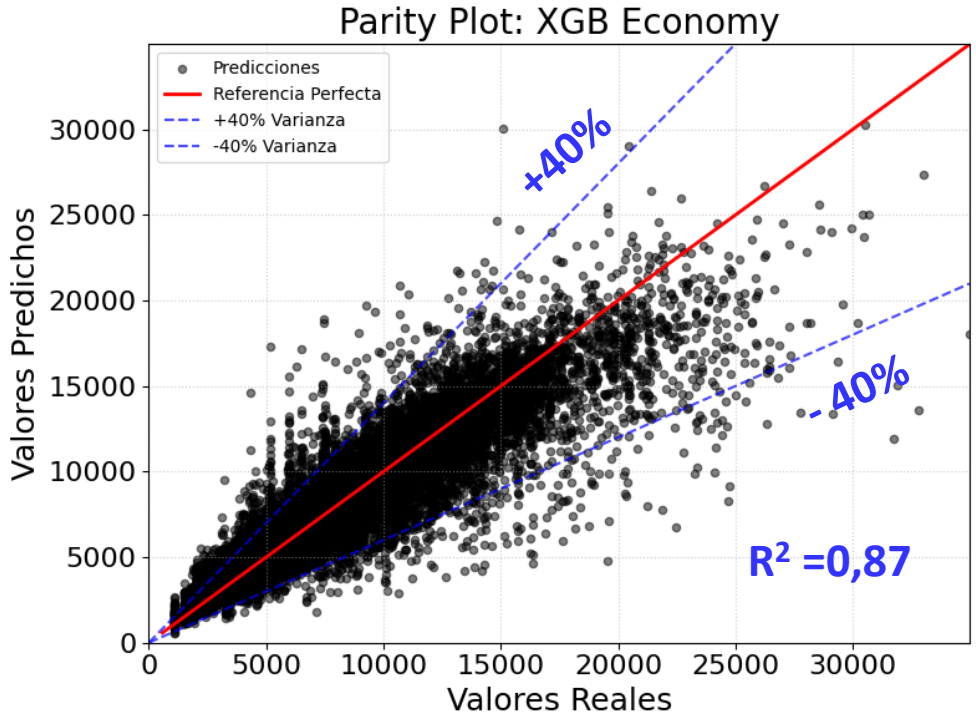

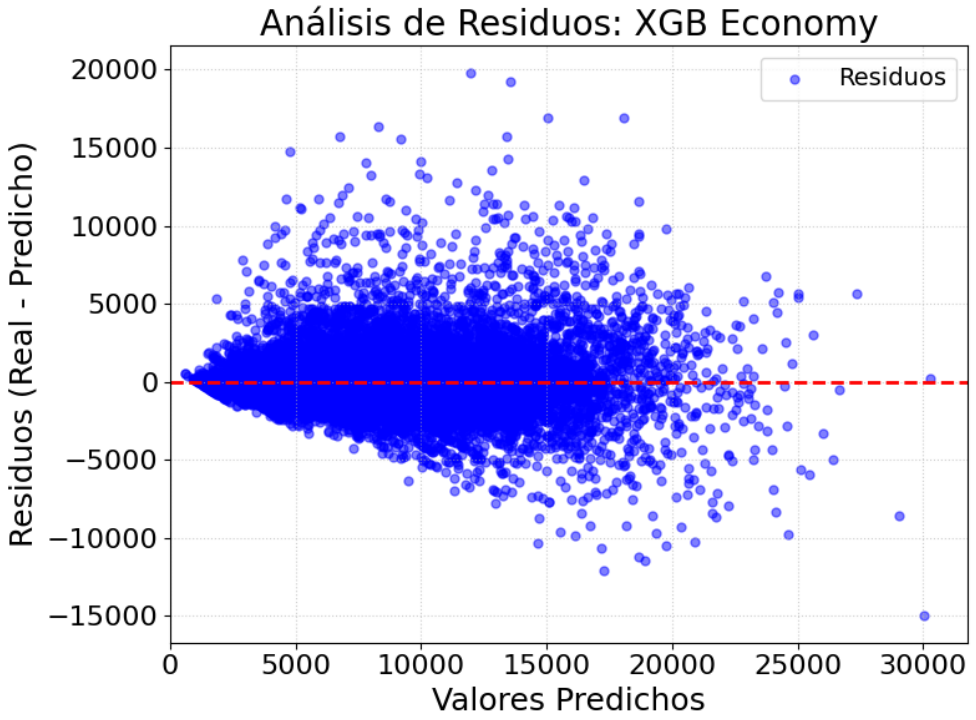

Optimización con Optuna (dataset business)

- Optimización bayesiana hiperparámetros:
  - "n_estimators": 785
  - "max_depth": 8
  - "learning_rate": 0.099
  - "subsample“: 0.757
  - "colsample_bytree": 0.587

RMSE = **3786 INR** (~36€)

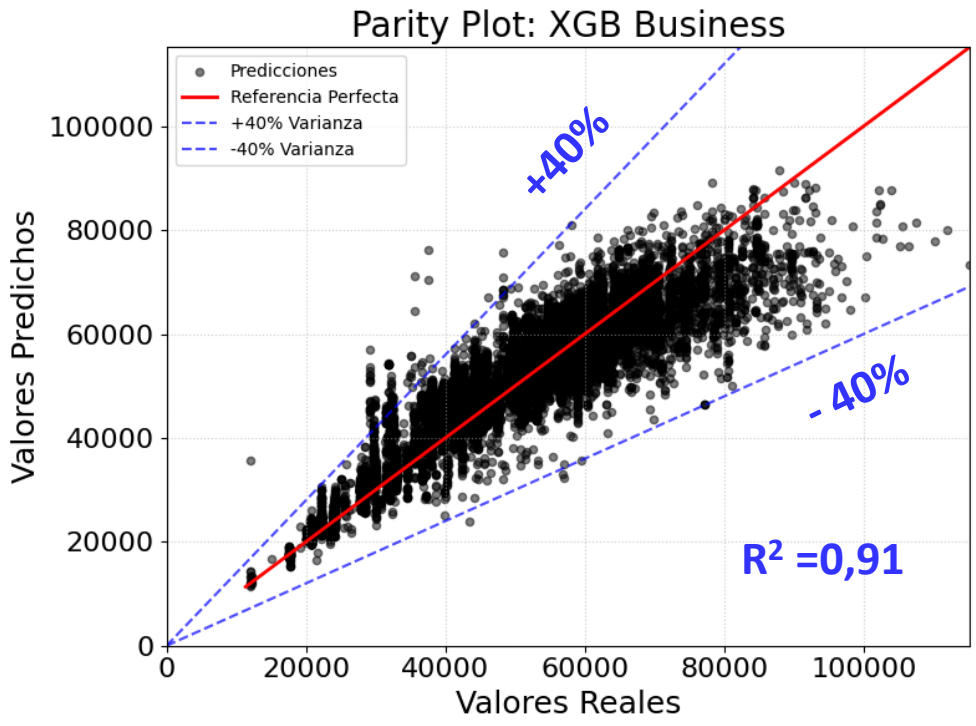

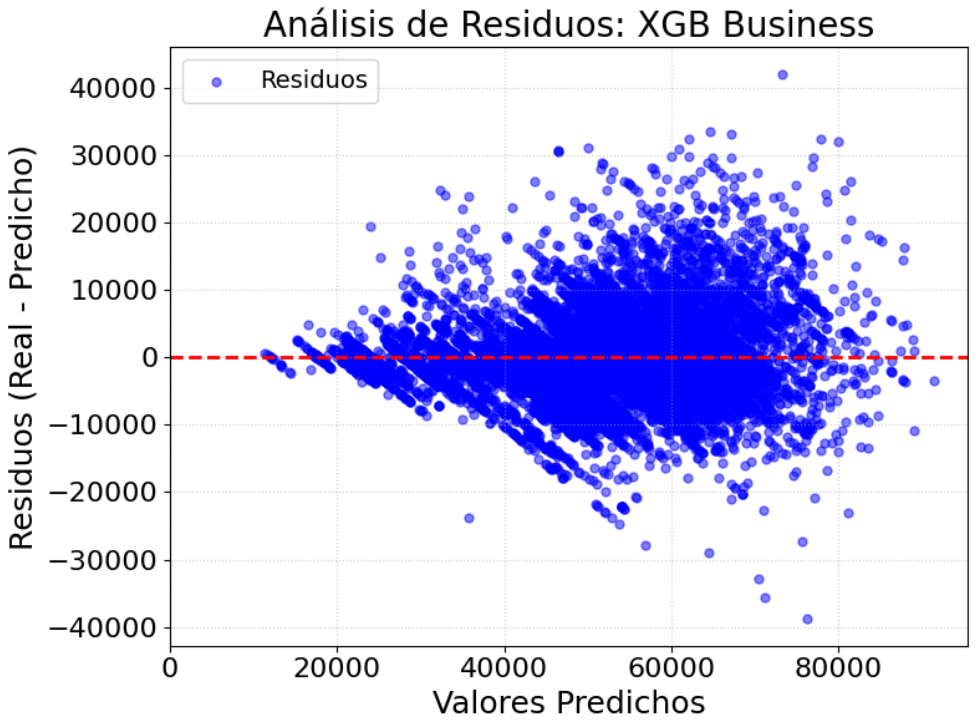

Conclusiones

Modelo Economy	Modelo Business
División 80% train / 20% test.	División 80% train / 20% test.
Validación cruzada sobre el 80% de entrenamiento.	Validación cruzada sobre el 80% de entrenamiento.
XGBoost base (XGB). RMSE = **1771 INR** (~17€).	**Modelos base (XGB).** RMSE = **5536 INR** (~52€).
XGBoost optimizado (Optuna): RMSE CV = **1377 INR** (~13€).	**XGBoost optimizado (Optuna):** RMSE CV = **3931 INR** (~37€).
Test final: RMSE = **1329 INR** (~13€).	**Test final:** RMSE = **3786 INR** (~36€).
Conclusión: CV y test muy similares → **excelente generalización**, sin overfitting.	**Conclusión:** CV y test muy próximos → **modelo robusto** pese a la alta variabilidad de Business.

Extra: modelo de clasificación (economy + business)

- Pasos previos a modelado (target = class):
  - ETL: igual
  - Selección features: todas incluido “stop_num”
  - Eliminar Price (variable dependiente)
  - Procesado features: OneHotEncoder

- Métricas (Validación cruzada)

F1-macro*	Balanced Accuracy	ROC-AUC
M1: RandomForestClassifier		
0,41	0,50	0,77
M2: XGB Classifier		
0,63	0,62	0,79
M3: LGBMClassifier		
0,61	0,61	0,78

- Optuna
  Hiperparámetros:
  - "scale_pos_weight": 2,99
  - "max_depth": 9
  - "learning_rate": 0,05
  - "n_estimators": 540
  - "subsample": 0,97 | 0,92 (bytree)
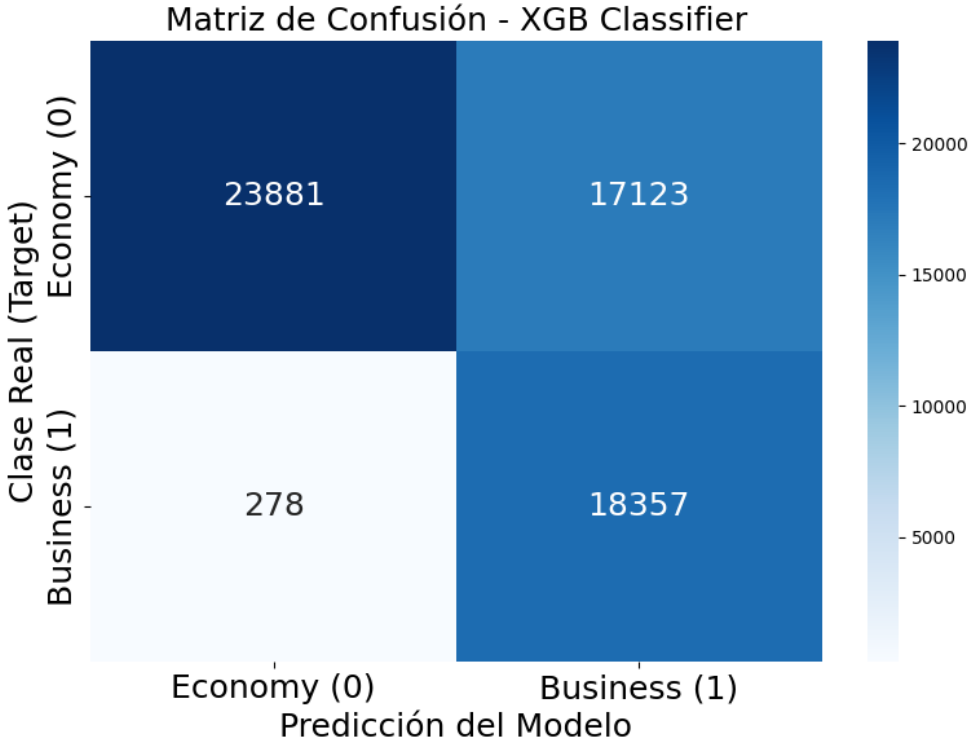
F1-macro=0,7